

Real-Time Event Processing with Microsoft Azure Stream Analytics

Björn Beha und Suhay Sevinc

Zusammenfassung—Der Artikel befasst sich mit Microsofts Cloud-Plattform Azure und dem darauf angebotenen Dienst zur Echtzeit-Eventverarbeitung - Azure Stream Analytics. Die Arbeit konzentriert sich auf die Rolle des Service innerhalb der Plattform und dessen Leistungsumfang. Für eine kritische Auseinandersetzung mit dieser Technologie werden die offiziellen Angaben von Microsoft herangezogen, ausgewertet und mit der kosten- und lizenzfreien Alternative Apache Storm verglichen. Die Abhandlung beinhaltet eine Auswertung der Unterschiede dieser Untersuchung, welche unter anderem die Skalierbarkeit und Verfügbarkeit der Systeme betrachtet. Unter Berücksichtigung dieser Ergebnisse erfolgt eine Bewertung. Die Gegenüberstellung zeigt, dass sich die beiden Technologien nicht direkt vergleichen lassen. Azure Stream Analytics stellt ein fertigen Dienst dar (Software-as-a-Service), während ein Apache Storm-System über eine eigene Implementierung realisiert wird. Azure Stream Analytics zielt auf Domänenexperten ab, die kaum Programmierexpertise besitzen bzw. diese gar nicht benötigen, wohingegen Apache Storm fundierte Kenntnisse erfordert.

Index Terms—Microsoft, Azure, Stream Analytics, Real-Time, Event-Processing, Apache Storm



1 EINFÜHRUNG

„In the Internet of Things [...] the real value will remain in the services behind the scenes processing terabytes of data to help people live better lives.“ [1]

Die zunehmende Anzahl von leistungsfähigen und intelligenten Geräten wie beispielsweise Sensoren, Smartphones etc., fördern laufend die Entwicklung von Anwendungen zur Datenstromanalyse, um Ereignisse in Echtzeit zu überwachen. Die massiven Datenströme, die durch diese Gerätschaften generiert werden, haben das Internet der Dinge (IoT) zu einer wichtigen Quelle für Big Data gemacht [2]. Bereits heute sind über 20 Milliarden Geräte mit dem Internet verbunden und laut Prognosen sollen diese Zahlen bis in wenigen Jahren drastisch anwachsen [3]. Das damit verbundene Wachstum der zu verarbeitenden (nicht-endlichen) Datenströme, stellt eine zunehmende Herausforderung dar. Nicht zuletzt, weil diese Daten in Echtzeit verarbeitet werden sollen und sie sich ständig in Bewegung befinden [2].

Ereignisgesteuerte Systeme, die einen Strom von Sensordaten auswerten, um relevante Informationen zu extrahieren, brauchen eine automatische Verarbeitung dieser Daten. Genau hier setzt Real-Time Stream Analytics an. Microsofts Cloud-basierte Lösung leitet aus einem unendlichen Datenfluss Muster und komplexe Ereignisse ab, wodurch es einem solchen System ermöglicht wird, auf Situationen entsprechende Maßnahmen anzuwenden und so geeignet darauf zu reagieren. So ist beispielsweise das Abfangen kritischer Situationen in der Produktion möglich und es können potenzielle Ausfälle von Maschinen rechtzeitig erkannt und vermieden werden [4]. Jedoch offeriert nicht nur Microsoft eine Lösung im Bereich Complex Event Processing. Opensource-Produkte wie Apache Storm bieten hier eine Alternative. Laut Microsoft ist Azure und die darauf angebotenen Dienste eine

unglaublich gute Sache. In dieser Arbeit werden diese beiden Technologien miteinander verglichen. Vorab wird kurz erläutert, wobei es sich um Complex Event Processing handelt. Dies ist für das weitere Verständnis der Arbeit wichtig. Anschließend erfolgt eine Beschreibung von Microsofts Cloud-Plattform. Auf diese baut das Kapitel auf, in welchem der Azure-Dienst Stream Analytics genauer beschrieben und auf dessen Features näher eingegangen wird. Daraufhin erfolgt der Vergleich beider Echtzeitverarbeitungssystemen sowie eine abschließende Bewertung. Diese Arbeit zielt auf Leser ab, welche sich mit dem Azure-Dienst auseinandersetzen möchten. Es werden hier keine tiefgreifenden Informationen geliefert.

2 VERWANDTE ARBEITEN

Die Recherche zeigt, dass im Bereich Complex Event Processing einige Arbeiten existieren, die sich mit den verschiedenen Aspekten von Apache Storm auseinandersetzen. Jedoch existieren im Kontext Azure Stream Analytics keine wissenschaftlichen Arbeiten, die den Funktionsumfang dieser Technologie bezeugen und kritisch beanstanden. Weiterhin gilt es zu betonen, dass es sich bei Stream Analytics um ein kommerzielles Produkt handelt, welches keine direkte Analyse über den Quellcode zulässt. Folglich kann in dieser Artikel nicht auf unabhängige und kritische Arbeiten angelehnt und verwiesen werden. Diese Arbeit stützt sich auf Literatur verschiedener Autoren, die mit Microsoft in Verbindung gebracht werden können. [5] [6].

3 STREAM ANALYTICS UND COMPLEX EVENT PROCESSING

Stream Analytics beschreibt grundlegend das Analysieren und Verarbeiten von Datenströmen, allerdings zur Laufzeit und nahezu in Echtzeit. Das bedeutet, dass die Zeit zwischen Datenaufnahme und Ergebnissen möglichst

gering ist. Typischerweise wird dies in Sekunden gemessen. Grundsätzlich geht es bei der Verarbeitung um das Filtern, Aggregieren und Suchen von Mustern. Die Resultate lassen sich anschließend an entsprechende Anwendungen weiterleiten. Stream Analytics gehört somit zum Themenbereich von Complex Event Processing [7].

Complex Event Processing ist ein Sammelbegriff. Dieser umfasst Methoden, Techniken und verschiedene Werkzeuge, mit denen voneinander unabhängige Ereignisse stetig und zeitnah verarbeitet werden. Um auf Ereignisse zu reagieren, werden aus dem eingehenden Datenstrom benötigte Informationen extrahiert. Typische Reaktionen wären das Senden von Benachrichtigungen, einfache Aktionen oder Interaktionen mit Geschäftsprozessen [7]. Es können mehrere einzelne Ereignisse verbunden werden, sodass sie ein komplexes Ereignis ergeben. Für verschiedene Situationen ist es zudem notwendig, dass Ereignisse in einem gewissen Zeitraum bzw. einer bestimmten Reihenfolge auftreten. Somit sind zeitliche Zusammenhänge ebenfalls von Bedeutung. Da der Ereignisstrom unendlich ist, sind Abfragen nur in bestimmten Ausschnitten (Fenstern) denkbar [7].

Datenströme bestehen häufig zu einem Großteil aus irrelevanten Daten („noise“). Nur ein Bruchteil bilden dabei Nutzdaten („signal“). Ein solches System filtert diese über geeignete Mechanismen heraus. Das ermöglicht eine Konzentration der relevanten Anteile, während beispielsweise Messfehler direkt aussortiert werden. Nachfolgend sind die Nutzdaten mit anderen Datenströmen in Bezug zu setzen. Durch diese Korrelation der einzelnen Sensordaten ergeben sich Ereignisse. Zusätzlich können die Daten mit Informationen aus unterschiedlichen Datenbanken angereichert werden. Dies kann nützlich sein, um noch aussagekräftigere Ergebnisse zu erzielen. Dabei ist vor allem die zeitliche Komponente ein wichtiger Faktor. Da Ereignisse, die in einem bestimmten Zeitraum auftreten von großer Bedeutung sein können, gibt es die bereits erwähnten Funktion der Zeitfenster. Nach dieser Vorverarbeitung des Ereignisstroms lassen sich die Daten gezielt nach definierten Mustern absuchen. Werden entsprechende Muster gefunden, kann das System darauf reagieren. Hier liegt der eigentliche Wert dieser Technologie [8].

4 MICROSOFT AZURE

Azure ist Microsofts Hybrid-Cloud-Plattform, die seit 2010 verfügbar ist. Dies bedeutet, dass Daten sowie Apps lokal und in der Cloud gespeichert und verknüpft werden können. Azure enthält eine stetig wachsende Anzahl an Tools, Diensten, Anwendungen und SQL- sowie NSQL-Datenbanken, die dem Nutzer über das Portal angeboten werden. Zudem bieten sie umfassende Dienste für künstliche Intelligenz, mit der die Entwicklung umfangreicher, intelligenter Anwendungen ermöglicht wird. Nutzer können über Azure auf Hochleistungsgrafikprozessoren zugreifen, wodurch ihnen die Entwicklung im Bereich autonomes Fahren, Spracherkennung sowie Daten- und Videoanalyse

erlaubt wird. Neben umfangreicher Prozessorleistung stellt Microsoft auch Speicherplatz zur Verfügung. Somit erlaubt Azure das sichere Speichern eigener Daten in der Cloud [9]. Des Weiteren möchte Microsoft damit die IT in Unternehmen flexibler gestalten, da sich mit Cloud-Computing Infrastrukturen in Form von virtuellen Servern oder Load Balancern digital zur Verfügung stellen lassen. Stichwörter hier sind Infrastructure-, Plattform- und Application-as-a-Service. Auch Lösungen unter Einbeziehung von beliebige Entwicklungstools oder -sprachen werden dem Anwender ermöglicht [6].

Grundlage der Azure-Plattform ist ein wachsendes Netzwerk aus verteilten Rechenzentren. Somit kann eine enorm hohe Verfügbarkeit gewährleistet werden. Die Sicherung der eigenen Anwendungen und Daten wird durch diese Hochverfügbarkeit und eine Notfallwiederherstellung gewährleistet. Durch kontinuierliche Investitionen in die neueste Infrastrukturtechnologie, bleibt Microsofts Plattform zuverlässig, kosteneffizient und umweltverträglich [6].

Derzeit liegt Microsoft hinter dem Marktführer Amazon, welches in 1 illustriert wird. Auf der offiziellen Website von Azure wird die Frage gestellt ‚Azure oder AWS?‘. Microsoft gibt darauf eine prägnante Antwort: ‚Azure ist die richtige Wahl‘ [10].




Abbildung 1. Marktanteil nach Umsatz [11]

Azure und AWS sind beides solide Plattformen. Beide haben ihre Vor- und Nachteile. Welche sich tatsächlich besser eignet, hängt von der Anforderung ab [12]. Was Azure allerdings besonders zugute kommt, ist die ergonomische Benutzeroberfläche zum Aufsetzen komplexer Systeme. Dies ist durch das Verknüpfen verschiedener Dienste möglich. Die Schritt-für-Schritt-Anleitungen, die dem Anwender zur Verfügung gestellt werden, zeigen, dass die Einrichtung entsprechender Dienste, Server und Cloud-Instanzen mit wenig Aufwand durchzuführen ist. Somit macht es den Übergang zur Cloud-basierten Infrastruktur für viele Unternehmen

unbeschwerter. Vor allem das nahtlose Zusammenarbeiten der angebotenen Dienste bzw. Azure-Instanzen erlaubt es, eine robuste Infrastruktur aufzubauen. Als Exempel kann hier der IoT Hub und die sich daran anschließende Ereignisverarbeitung Stream Analytics dargelegt werden [12].

Microsoft bietet auch bereits einsatzbereite Lösungen, die vollständig vorkonfiguriert sind. So lassen sich die häufigsten Szenarien im IoT-Bereich direkt aufsetzen, ohne dass es Cloud-Wissen oder Software-Know-How bedarf. Abbildung 2 zeigt die fertige Lösung zur Überwachung der Telemetrie einiger Geräte.

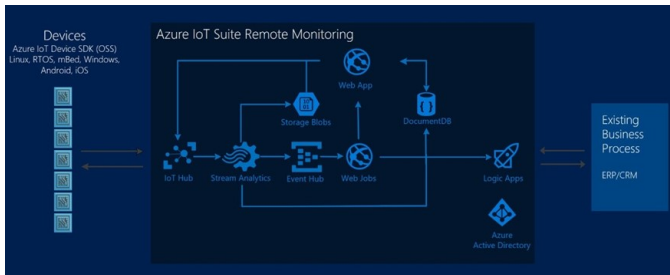


Abbildung 2. Fertige Remote Monitoring-Lösung [13]

Eine weitere direkt verfügbare Lösung wäre der bereits erwähnte vorhersagbare Wartungsbedarf. Diese Systeme sind Teil der IoT bzw. Cortana Suite. Beide Angebote bestehen aus einer Reihe von Azure-Diensten und können über ein monatliches Abonnement erworben werden. Eine Azure-Instanz besteht dabei aus einem virtuellen Server. Dieser wird über Hyper-V (Microsofts Hypervisor zur Visualisierung ihrer Server [14]) betrieben. Kosten fallen nach Verwendung eigener Cloud-Instanzen an. Bei Stream Analytics steht das Kontingent der verarbeiteten Daten im Vordergrund [12].

5 AZURE STREAM ANALYTICS

Vor allem im heutigen Industrie 4.0 Umfeld sammeln sich schnell umfangreiche Datenmengen. Diese können oft nur über einen (stark) begrenzten Zeitraum zurückgehalten werden, da sie ansonsten ihre Aussagekraft verlieren. Ab diesem Punkt muss eine Datenverarbeitung erfolgen. Hier bietet Azure Stream Analytics eine Lösung. Dieser Dienst erlaubt Einblicke in Daten, um darin beispielsweise nach Mustern oder Anomalien zu suchen und entsprechend darauf zu reagieren [6]. Azure Stream Analytics unterstützt dabei eine SQL-Ähnliche Abfragesprache Stream Analytics Query Language (SAQL), über welche man die dynamischen Datenströme analysiert. Diese ist das Herzstück des Dienstes. Obwohl SAQL von der allgegenwärtigen SQL-Abfragesprache abgeleitet wurde, enthält es einzigartige Funktionen, die für die Stream-Verarbeitung notwendig sind [2]. Eine dieser Funktionen ist die Möglichkeit, Ergebnisse mithilfe von Zeitfenstern zu erhalten (siehe Fensterfunktionen). Ein typisches Echtzeitverarbeitungssystem, welches auf Stream Analytics und weiteren Azure-Diensten aufbaut, ist in Abbildung 3

aufgeführt.

Die linke Spalte zeigt Sensoren, Geräte und andere Datenquellen einer IoT-Lösung. Diese senden permanent Daten über das Cloud Gateway an die Azure Hubs. Der Gateway-Dienst ist hierbei ein virtuelles Gerät und ermöglicht eine konsistente Verbindung. Die Hubs sind in der Lage Millionen von Ereignissen pro Sekunde zu verarbeiten. Von dort aus werden sie an die weiteren Anwendungen übergeben. Stream Analytics transformiert eingehenden Daten. Die Ausgaben lassen sich daraufhin auf eine Vielzahl von Endpunkten richten. Azure bietet hier einige Dienste, welche daran angeknüpft werden können [2].

Sowohl Ein- als auch Ausgaben, die ein Stream Analytics-Job benötigt, werden im Azure-Portal konfiguriert. Ein einzelner Stream Analytics-Job kann mehrere Eingaben enthalten. Durch Aggregation der Datenströme lassen sich kombinierte Abfragen durchführen. Dies kann mit einem JOIN in SQL verglichen werden. Dadurch, dass ein einzelner Stream Analytics-Job mit mehreren Ein- und Ausgängen konfiguriert werden kann, ermöglicht umfangreiche Topologien [2]. Zur Verfügung stehen hier Services wie:

- Azure-Event-Hub
- Azure-IoT-Hub
- Azure-Blobspeicher
- Azure-Tabellenspeicher
- Azure-Ereignis-Hub
- Azure-Servicebus-Thema
- Azure Service Bus-Warteschlange
- Azure DocumentDB
- Microsoft Power BI
- Azure Data Lake Store

5.1 Fensterfunktionen

Das Hauptfeature der Stream Analytics-Abfragesprache SAQL ist die Unterstützung von Fensterfunktionen. Nachfolgend werden die Funktionen aufgeführt [2]:

- TumblingWindow
- HoppingWindow
- SlidingWindow

Zeitfenster erlauben es für Datenströme temporale Vorgänge durchzuführen. Die Ausgabe eines Fensters ist ein einzelnes Ergebnis, welches auf der verwendeten Aggregatfunktion basiert (siehe 4).



Abbildung 4. Fensterkonzepte [2]

Das Resultat enthält einen Zeitstempel vom Ende des Fensters. Ein Fenster wird stets über eine feste Länge

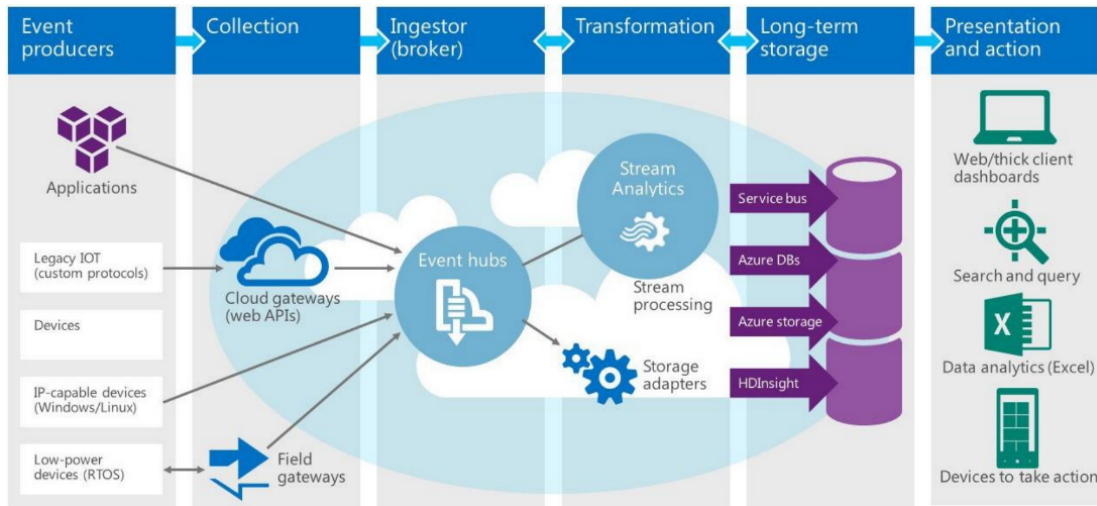


Abbildung 3. Typisches Echtzeitverarbeitungssystem [2]

definiert. Alle angewandten Fensterfunktionen bzw. deren Ergebnisse sollten mit einer GROUP BY-Klausel entsprechend zusammengeführt werden [13]. Als Exempel dient eine Aggregatfunktion, die aufzeigt, wie viele Autos einer speziellen Farbe alle fünf Minuten eine Mautstelle passieren [2]. Mit TumblingWindow wird ein Datenstrom in einzelne Zeitsegmente unterteilt. Für diese unterteilten Segmente wird eine Funktion ausgeführt. Die eben beschriebene Abfrage kann hier 1:1 ausgedrückt werden. Bei den rollierenden Fenstern gibt es keine Überlappungen und ein Ergebnis kann nicht zu mehreren Fenstern gehören. Bei HoppingWindow wird immer für einen festen Zeitraum einen Sprung nach vorne durchgeführt. Grundsätzlich kann dieser Ansatz wie das TumblingWindow angesehen werden, bloß überlappen sich die wiederholenden Fenster. Durch diesen Umstand kann es sein, dass ein Ergebnis zu mehreren Fenstern gehören kann. Die Abfragen lässt sich ähnlich ausdrücken, allerdings kann hier unabhängig von der Fenstergröße eine Ausgabe erzeugt werden. Es lässt sich beispielsweise einmal pro Minute ausgegeben, wie viele Autos einer speziellen Farbe alle fünf Minuten diese Mautstelle anfahren. SlidingWindow hingegen erzeugt nur ein Ereignis, wenn entsprechende Anforderungen erfüllt sind bzw. Ereignisse auftreten [13]. Auch hier können Ergebnisse zu mehreren Fenstern gehören. Dieser Ansatz lässt die Abfrage zu, in welchen 5-Minuten-Zeitfenstern zehn oder mehr Autos einer speziellen Farbe die Mautstelle erreichen. SlidingWindow ist somit für den Umgang mit relativ spärlichen Ergebnismengen geeignet [2].

6 LAMBDA-ARCHITEKTUR

„Mithilfe des Lambda-Architektur-Konzepts haben wir eine Architektur geschaffen, für die immer stärker wachsende Datenberge und neue Anforderungen der Zukunft kein Problem darstellen.“ [15, S.2]

Um die entstehenden Herausforderungen bei der Echtzeitverarbeitung großer Datenmengen zu bewältigen, ist die Lambda-Architektur ein erforderlicher Ansatz. Diese Big-Data-Architektur weist eine geringe Latenz

zwischen Ein- und Ausgabe auf und eignet sich für das Arbeiten mit hohen Rechenkomplexitäten. Aufgrund dessen findet sie sich in Stream Analytics-Frameworks [5]. Die Lambda-Architektur ist ein populäres Big-Data-Pattern und beschreibt den konzeptionellen Aufbau einer Big-Data-Architektur, bestehend aus einem zentralen Eintrittspunkt. Die Architektonik besteht aus zwei Kernschichten: Batch- und Speed-Layer. Eine Vereinigung dieser Schichten führt zu einer Echtzeitübermittlung der Daten. Die Umsetzung der Lambda-Architektur erfolgt in vielen Fällen nicht in reiner Form. Heterogene Systemlandschaften sehen dieser zwar ähnlich, weisen allerdings eine andere Interaktion zwischen den Komponenten auf, da beispielsweise verschiedene Anwendungsfälle unterschiedliche Schwerpunkte haben.

Speed Layer. Dieser hat zur Aufgabe, möglichst aktuelle Daten zu liefern. Dabei wird nicht auf Datenvollständigkeit und -korrektheit geachtet. Durch die hohe Frequenz, in welcher die Daten empfangen werden, ist eine vollständige Verarbeitung nicht möglich bzw. gar nicht zwanghaft notwendig. Verschickt ein Temperatursensor Messwerte in Millisekunden-Abständen, wäre auch eine Abarbeitung jedes tausendsten Sensorwerts ausreichend. Ein Ausschöpfen sämtlicher Daten würde an dieser Stelle keinen Mehrwert bedeuten. Hier geht es um eine Minimierung der Verzögerungslücke, welche durch den Batch Layer verursacht wird. Die Verarbeitung der Daten geschieht im besten Fall vollständig in-Memory.

Batch Layer. Diese Schicht berücksichtigt bei der Verarbeitung sämtliche Daten und achtet auf das Erbringen exakter Ergebnisse. Im Gegensatz zum Speed Layer müssen die Daten nicht im Speicher gehalten werden. Sie ermöglicht die Durchführung von Fensterfunktionen. Beispielsweise wäre ein Trainingsmodell aus dem Bereich „Machine Learning“ ein Anwendungsfall, welches Microsoft Azure ebenfalls unterstützt [16].

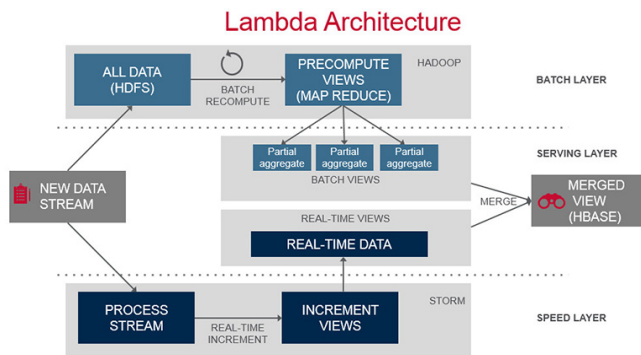


Abbildung 5. Aufbau der Lambda-Architektur

7 STREAM ANALYTICS UND APACHE STORM IM VERGLEICH

In diesem Abschnitt werden die beiden Analyseplattformen verglichen.

7.1 Lizenzmodell

Stream Analytics ist ein kommerzielles Produkt, welches nur innerhalb Azure genutzt werden kann. Hier kommt das Pay-As-You-go-Geschäftsmodell zum Einsatz, welches den Nutzern die Möglichkeit gibt, ausschließlich für den verursachten Datenverkehr zu bezahlen [17]. Desto höher das Datenvolumen, desto teurer wird die Nutzung. Damit können sowohl Kleinunternehmen als auch Großunternehmen dieses Produkt erwerben. Microsoft hat zudem die Cortana Analytics Suite für Unternehmen jeder Größe entwickelt. Kleinere Unternehmen können davon profitieren, dass keine Investitionen oder teure Software-Lizenzen für den Start benötigt werden. Größere Unternehmen können von der Skalierbarkeit der Azure Cloud-Plattform profitieren [13]. Apache Storm hingegen steht unter der Apache-Lizenz und ist somit kostenlos nutzbar [18].

7.2 Skalierbarkeit

Da Azure sämtliche Hardwareressourcen bereitstellt, bestehen für die Nutzer keine speziellen Hardwareanforderungen. Welche Anforderung Stream Analytics an die genutzte Cloud-Infrastruktur zugrunde legt, bleibt Microsoft vorbehalten und ist nicht bekannt [19]. Die Skalierung wird seitens Microsoft automatisch geregelt, sodass ein Event-Verkehr von einem Gigabyte pro Sekunde verarbeitet werden kann [20]. Apache Storm dagegen ist eine Standalone-Applikation und kann daher auf eigenen Systemen betrieben werden. Laut Apache kann mit 24 Gigabyte Arbeitsspeicher und 2-Intel-Prozessoren ein Kontingent von 100 Million Byte-Messages verarbeitet werden [21]. Auch hier sind keine konkreten Hardwarebedingungen gegeben. Diese sind abhängig vom Anwendungsfall und hängen von der Anzahl der Knoten ab [19].

7.3 Verfügbarkeit

Beide Analyse-Plattformen versprechen hier eine Verfügbarkeit von 99.9 Prozent. Für eine Hochverfügbarkeit bietet Azure eine Wiederherstellungsmöglichkeit für den Fall,

dass Fehler auftreten. Bei Apache Storm trägt der Benutzer die Verantwortung der Sicherheit seiner Daten [19] [21].

7.4 Entwicklungsumgebung

Stream Analytics unterstützt zwei Ansätze, einen Auftrag zu erstellen:

- Azure-Portal
- REST

Im ersten Fall kann der Benutzer über eine entsprechende Benutzeroberfläche einen Job erstellen [22]. Die zweite Möglichkeit geht über eine REST-Schnittstelle, welche über Quellcode angesprochen wird. Somit ist es möglich via eigener Implementierung Jobs zu erstellen, diese zu automatisieren und zu re-/konfigurieren [23]. Apache Storm erfordert ein eigenverantwortliches Aufsetzen des gesamten Systems [24].

7.5 Abfragesprachen

Wie bereits erwähnt stellt Microsoft eine SQL-ähnliche Sprache zur Verfügung, mit welcher Abfragen erfolgen. In Kombination mit Scope definiert ASQL eine neue deklarative Big-Data-Sprache [25]. Aus dem obigen Kapitel hervorgehend werden temporale Operatoren unterstützt. In Apache Storm sind Abfragesprachen nicht standardmäßig enthalten. Hierfür muss der Anwender Programmcode schreiben, was Programmierkenntnisse voraussetzt. Auch Fensterfunktionen werden ebenfalls nicht unterstützt und erfordern eine eigene Implementierung [19]. Allerdings kann Apache Storm durch Einsatz von Fremdbibliotheken an Abfragesprachen, wie zum Beispiel "Esper" erweitert werden [26].

7.6 Debugging-Unterstützung

Zum Debuggen steht ein Protokoll zur Verfügung, welches den Auftragsstatus und die Auftragsvorgänge aufzeigt. Jedoch können Benutzer die Debugg-Inhalte nicht anpassen. Der Anwender keine personalisierte Logdatei erstellen. Auf Seitens Apache Storm gibt es kein automatisches Logging. Dies liegt vollständig in der Hand des Entwicklers. Er kann das Logging dafür frei gestalten [27].

7.7 Datenformate

Stream Analytics beschränkt sich auf die Datenformate Avro, JSON und CSV. Apache Storm hingegen kann beliebige Datenformate nutzen. Das ermöglicht eine dynamischere Entwicklung [6].

8 FAZIT UND AUSBLICK

Storm genießt einen großen Einfluss in der Big-Data-Community und ist äußerst skalierbar, fehlertolerant und kann in bestehende Technologien integriert werden. Große Namen wie Twitter greifen darauf zurück, um ihre Daten in Echtzeit zu analysieren. Allerdings ist die Einrichtung von Apache Storm keinesfalls trivial. Anfängliche Investitionen in Hardware und womöglich Software können zudem anfallen. Dies ist der große Vorteil von Azure Stream Analytics, welches im Grunde keine

Einrichtung und/ oder Wartung erfordert, da es von Microsoft als Dienst (Software-as-a-Service) angeboten wird. Nicht jeder Anwender verfügt über fundamentale Programmierkenntnisse, um ein CEP-System aufzusetzen. Daher ist Stream Analytics ein profitables Produkt für Unternehmen, die einen umfangreichen initialen Aufwand nicht stemmen wollen oder können. Dies mag unter anderem an mangelndem Expertenwissen liegen. Das Einrichten eines Jobs beschränkt sich hier auf wenige Klicks im Azure-Portal. In ihm werden sämtliche Ein- und Ausgaben konfiguriert sowie entsprechende Abfragen ausgeführt. Auf die Skalierbarkeit wird bei Azures Diensten viel Wert gelegt. Ein einzelner Job kann bereits Millionen Ereignisse pro Sekunde verarbeiten. Da es mit anderen Diensten auf der Azure-Plattform angeboten wird, erlaubt es außerdem ein nahtloses Kombinieren verschiedener Azure-Services. Dazu zählen die in diesem Artikel aufgelisteten Produkte (Azure Storage, Azure SQL Database und Microsoft Power BI). Wie aus der Arbeit hervorging, werden auch einige, häufig vorkommende Szenarien als vorkonfigurierte Lösung angeboten um die anfänglichen Hürden noch weiter zu reduzieren.

Durch die von SQL abgeleitete Abfragesprache können Nutzer bereits eine bekannte Sprache verwenden, um die Daten zu analysieren oder persistent zu speichern usw. Es zielt zunehmend auf Analysten ab, da keine Programmierexpertise vorausgesetzt wird. Zudem fällt das Aufsetzen von bestimmten Umgebungen vollständig weg. Jedem Nutzer wird dabei ein Ansprechpartner delegiert. Während bei Storm mit Spouts und Bolts gearbeitet wird, weiß man bei Azure Stream Analytics nicht direkt, wie die Daten intern verarbeitet werden. Einiges deutet darauf hin, dass auch Azure Stream Analytics ähnlich vorgeht. Der Anwender muss hier jedoch nicht wissen, was unter der Haube steckt. Es soll kein Software-Know-How erforderlich sein. Es ist möglich eine entsprechende Lösung zu konfigurieren, ohne zu wissen wie sie intern funktioniert. Bei Storm hingegen braucht man umfangreiche Einblicke in die Technologie, da ansonsten das Implementieren einer Lösung unmöglich wäre.

Obwohl Stream Analytics bereits einige Zeit auf dem Markt ist, gibt es keinerlei wissenschaftliche Artikel, welche sich kritisch mit der Thematik auseinandersetzen. Es sind lediglich von Microsoft zur Verfügung gestellte Literatur, Beispiele und Dokumentationen zu finden. Aufgrund der stark begrenzten Quellen, war es leider nicht möglich tiefgreifende Einblicke zu erhalten. Die offiziellen Angaben der Anbieter klingen sehr vielversprechend, doch eine Überprüfung dieser Werte steht noch aus. Trotz mangelnder Hintergrund bzgl. der präzisen Funktionsweise von Azure Stream Analytics sind wir der Meinung, dass es eine gewinnbringende Plattform darstellt. Künftig wird die Entwicklung dieses Dienstes weiterhin verfolgt. Der bisherige Mangel an wissenschaftlichen Artikeln könnte sich noch ändern, da schließlich immer mehr Geräte Teil einer IoT-Lösung werden und somit immer mehr Daten das Internet förmlich überfluten und analysiert werden müssen. Interessant bleibt auch die Entwicklung in Verbindung mit künstlicher Intelligenz bzw. maschinellem Lernen. Dies bietet nämlich eine mächtige Erweiterung zum Erkennen von Anomalien etc.

LITERATUR

- [1] Dr Floarea Serban and Dr. Yves Brise, "Complex event processing: Eine strategische big data entscheidung," 2014. [Online]. Available: <https://ipt.ch/complex-event-processing-eine-strategische-big-data-entscheidung/>
- [2] J. Prosise, "Understanding azure stream analytics," 2016.
- [3] Statista, "Iot: number of connected devices worldwide 2012-2025 — statista," 2017. [Online]. Available: <https://www.statista.com/statistics/471264/iot-number-of-connected-devices-worldwide/>
- [4] P. Tracy, "What is complex event processing and why is it needed for iot?" 2016. [Online]. Available: <https://www.rcrwireless.com/20161122/fundamentals/cep-iot-tag31-tag99>
- [5] B. Familiar and J. Barnes, *Business in Real-Time Using Azure IoT and Cortana Intelligence Suite*. Berkeley, CA: Apress, 2017.
- [6] S. Klein, *IoT Solutions in Microsoft's Azure IoT Suite*. Berkeley, CA: Apress, 2017.
- [7] Gesellschaft für Informatik, "Complex event processing (cep)," 2009. [Online]. Available: <https://gi.de/informatiklexikon/complex-event-processing-cep/>
- [8] A. Bruening, "Event-processing und stream-analyse," 2016.
- [9] Microsoft, 2017. [Online]. Available: <https://azure.microsoft.com/de-de/blog/stream-analytics-compliance/>
- [10] —, "Stream analytics - datenanalyse in echtzeit — microsoft azure," 2017. [Online]. Available: <https://azure.microsoft.com/de-de/services/stream-analytics/>
- [11] Statista, 2017. [Online]. Available: <https://de.statista.com/statistik/daten/studie/779775/umfrage/marktanteile-der-anbieter-am-umsatz-im-bereich-cloud-infrastructure-weltweit>
- [12] P. Tsai, 2016. [Online]. Available: <https://www.computerwoche.de/a/aws-versus-azure-die-vor-und-nachteile-aus-sicht-von-it-experten,3323128>
- [13] Microsoft, 2017. [Online]. Available: <https://azure.microsoft.com/searchdatacenter>
- [14] searchdatacenter, 2017. [Online]. Available: <http://www.searchdatacenter.de/definition/Microsoft-Hyper-V>
- [15] OPITZ CONSULTING, "Big data für macher - lambda-architektur und hadoop framework in der praxis — ein fachartikel von opitz consulting," 2017. [Online]. Available: https://www.opitz-consulting.com/fileadmin/user_upload/Collaterals/Artikel/it-management-2017-10_big-data-fuer-macher_berle_sicher.pdf
- [16] Lukas Berle, OPITZ CONSULTING Deutschland GmbH, "Lambda-architektur in der praxis," 2017.
- [17] Microsoft, "Pricing - stream analytics — microsoft azure," 2017. [Online]. Available: <https://azure.microsoft.com/en-us/pricing/details/stream-analytics/>
- [18] Apache, "Apache license, version 2.0," 2004. [Online]. Available: <http://www.apache.org/licenses/LICENSE-2.0.html>
- [19] Microsoft, "Analyseplattformen: Vergleich von apache storm mit stream analytics," 2017. [Online]. Available: <https://docs.microsoft.com/de-de/azure/stream-analytics/stream-analytics-comparison-storm>
- [20] —, "Introduction to stream analytics," 2017. [Online]. Available: <https://docs.microsoft.com/en-us/azure/stream-analytics/stream-analytics-introduction>
- [21] Apache, "Project information," 2017. [Online]. Available: <http://storm.apache.org/about/scalable.html>
- [22] Microsoft, "Stream analytics rest api," 2017. [Online]. Available: <https://docs.microsoft.com/de-de/rest/api/streamanalytics/?redirectedfrom=MSDN>
- [23] —, "Erstellen eines auftrags zur verarbeitung von datenanalysen für stream analytics," 2017. [Online]. Available: <https://docs.microsoft.com/de-de/azure/stream-analytics/stream-analytics-create-a-job#next-steps>
- [24] Apache, "Apache storm," 2017. [Online]. Available: <http://storm.apache.org/>
- [25] Microsoft, "Stream analytics query language reference," 2016. [Online]. Available: <https://msdn.microsoft.com/en-us/library/azure/dn834998.aspx>
- [26] espertech, "Esper," 2016. [Online]. Available: <http://www.esper.tech/esper/>

- [27] community.hortonworks, "Debugging an apache storm topology - hortonworks," 2016. [Online]. Available: <https://community.hortonworks.com/articles/36151/debugging-an-apache-storm-topology.html>